

Una bodega trazable para el archivo recibido

Grupo 1

Andres Felipe Castrillon Martinez


Bryan Panesso Avila

Juan David Turrigao Orozco

1. Pregunta y granularidad

¿Cómo se distribuye la cantidad registrada por tiempo, territorio, sexo y características del hecho? La tabla de hechos tiene **una fila por registro de la fuente**. No se presupone que cada fila sea un evento único o una víctima individual.

La medida aditiva es **cantidad**, que se suma en todos los cortes. COUNT(*) mide filas; SUM(cantidad) mide la cantidad registrada. En esta versión son 31.708 filas y 31.746 unidades, respectivamente.



Granularidad: una fila de origen. Medida aditiva: SUM(cantidad).

Modelo estrella. Cada dimensión se relaciona 1:N con el hecho. Fuente editable compatible con dbdiagram.io: entrega/diagrama_bodega.dbml.

Dimensiones y claves

2. Justificación de cada dimensión

Dimensión / granularidad	Atributos y razón de existir
Tiempo: una fecha observada	864 filas. tiempo_id, fecha, anio, mes, dia, trimestre. Permite ordenar y agrupar periodos; no se rellena el calendario con ceros ante cobertura incierta.
Ubicación: municipio y zona	1,565 filas. ubicacion_id, cod_departamento, departamento, cod_municipio, municipio, zona. Distingue zona urbana/rural del mismo municipio y nombres municipales repetidos entre departamentos.
Sexo: categoría registrada	3 filas. sexo_id y sexo. Permite cortes demográficos y conserva SIN ESTABLECER; no interpreta la categoría como riesgo individual.
Contexto: combinación de tres categorías	84 filas. contexto_id, arma_medio, modalidad_presunta, caracterizacion. Agrupa atributos descriptivos de baja cardinalidad que caracterizan el hecho. Cada combinación es única.

3. Hecho y relaciones

hecho_homicidios: hecho_id (PK); tiempo_id, ubicacion_id, sexo_id y contexto_id (FK obligatorias); cantidad (entero positivo); fuente_sha256 y fila_fuente (trazabilidad, pareja única). La fila de fuente incluye el encabezado: el primer dato corresponde a la fila 2 del CSV.

Las claves subrogadas enteras se asignan tras ordenar las combinaciones dimensionales distintas. Se reproducen con la misma fuente; una actualización del catálogo puede cambiarlas. La carga completa sustituye datos de hechos y dimensiones dentro de una sola transacción.

4. Por qué un modelo estrella

La desnormalización del departamento dentro de ubicación reduce uniones para las preguntas del curso. Sexo se separa para que sus categorías se validen y reutilicen. Contexto mantiene juntas las tres clasificaciones observadas, sin crear relaciones causales entre ellas.

Integridad y decisiones

5. Reglas de transformación

Se conserva el Excel y se genera CSV UTF-8 sin filtrar. En el ETL se normalizan espacios, mayúsculas y Unicode; las fechas se convierten con formato ISO explícito. Códigos de departamento y municipio se almacenan como texto de 2 y 5 posiciones; su prefijo debe coincidir.

Nombres vacíos completados desde una etiqueta única del mismo código: 1. Los cambios no sobrescriben el archivo recibido. Se conservan las 4,383 repeticiones exactas, pues no existe identificador para decidir si son errores o hechos diferentes.

6. Controles implementados

Capa	Control
Antes de cargar	Columnas esperadas; fechas válidas; cantidad entera positiva; códigos coherentes; claves únicas; merges many_to_one; conservación de filas y suma.
PostgreSQL	Cinco PK, cuatro FK, claves naturales UNIQUE, cantidad CHECK > 0 e índices sobre las FK. No se eliminan las restricciones con to_sql replace.
Transacción	Carga completa en esquema dedicado p1_homicidios. Si falla cualquier inserción o conciliación, se revierte. La recarga no acumula registros.
Después de cargar	COUNT(*) y SUM(cantidad) desde PostgreSQL; totales de las seis consultas reconciliados contra la fuente.

7. Límites conocidos

Las fechas del archivo solo contienen días del 1 al 12 de cada mes. No hay evidencia suficiente para atribuir la causa ni certificar cobertura completa. Los resultados siguientes describen esta versión del archivo.

La procedencia oficial, URL de descarga y pertenencia al catálogo siguen pendientes. No se dispone de población para calcular tasas ni de un identificador estable para deduplicar o hacer incrementos entre archivos.

Base documental: Proyecto 1.pdf, páginas 1-3; avances 01-04 aportados por el grupo; DataSetHomicidios2020-2025.xlsx, Hoja1. Huellas completas en datos/manifiesto.json.