

Homicidios registrados: distribución y calidad del archivo aportado

Grupo 1

Andres Felipe Castrillon Martinez

Bryan Panesso Avila

Juan David Turrigao Orozco

1. Objetivo y alcance

Construir una bodega dimensional reproducible, cargarla con Python en PostgreSQL y responder seis preguntas descriptivas mediante SQL y ocho visualizaciones. Los resultados se limitan al archivo aportado por el grupo.

Filas de origen	Suma de CANTIDAD	Fechas distintas
31,708	31,746	864

Advertencia de cobertura. Las fechas del archivo solo contienen días del 1 al 12 de cada mes. No hay evidencia suficiente para atribuir la causa ni certificar cobertura completa. Los resultados siguientes describen esta versión del archivo.

Preguntas abordadas

Q1. ¿Cómo cambia la cantidad registrada por mes y frente al mes anterior?

Q2. ¿Qué departamentos concentran la mayor cantidad registrada?

Q3. ¿Cómo se distribuye la cantidad por año, zona y sexo?

Q4. ¿Qué armas o medios predominan y cómo se distribuyen por sexo?


Q5. ¿Qué relación existe entre las cantidades urbanas y rurales por municipio?

Q6. ¿Cómo se distribuyen las cantidades mensuales de cada departamento?

Fuente recibida: DataSetHomicidios2020-2025.xlsx, Hoja1. Rango observado: 01-ene-2020 a 12-dic-2025. El nombre y el rango no acreditan completitud ni procedencia oficial.

Diseño y reproducibilidad

2. Modelo dimensional



Granularidad: una fila de origen. Medida aditiva: SUM(cantidad).

El hecho representa una fila de origen y contiene una medida aditiva, cantidad. Cuatro dimensiones permiten cortes de tiempo, ubicación, sexo y contexto. Las relaciones son 1:N y se verifican con claves foráneas físicas en PostgreSQL.

3. Pipeline y controles

El ETL lee CSV con pandas, normaliza textos, convierte tipos y construye claves subrogadas. La carga usa SQLAlchemy y DATABASE_URL de un .env local. La transacción conserva las restricciones y revierte cualquier error; ejecutar de nuevo no acumula filas.


La auditoría conserva 4,383 repeticiones exactas y registra las correcciones de nombres vacíos desde el mismo código geográfico (1 corrección). Se verifican filas y suma antes y después de cargar. Las seis consultas concilian 31,746 unidades.

Q1 usa LAG, Q2 usa RANK y Q3 agrupa tiempo, ubicación y sexo. Los notebooks C y D consultan la base por separado, sin depender del estado del kernel de B. Las ocho figuras reutilizan exclusivamente los resultados de Q1-Q6.

Evidencia técnica: documentacion/validacion.json. Instrucciones de ejecución y dependencias: README.md y requirements.txt. El acuerdo de grupo y las gestiones administrativas requieren confirmación humana.

Hallazgo 1

Concentración territorial



Fuente: archivo aportado por el grupo. Cobertura temporal pendiente de verificación.

4. Cantidades por departamento

VALLE DEL CAUCA tiene la mayor cantidad registrada: **5,589** unidades, equivalentes al **17.61%** del archivo. Los tres primeros departamentos concentran el **39.55%** de la suma.

La figura V2 procede de Q2: une ubicación con hechos, agrupa por código y nombre de departamento y calcula ranking y participación. El gráfico muestra diez departamentos; el denominador de las participaciones comprende todos los departamentos del archivo.


Interpretación y uso

Esta concentración ayuda a priorizar qué segmentos revisar y describir dentro de la bodega. No permite ordenar el riesgo de los territorios: faltan población, confirmación de cobertura y conocimiento del mecanismo de selección de registros.

Fuente: consulta Q2 sobre PostgreSQL; suma de CANTIDAD. Las diferencias son descriptivas y no establecen relaciones causales.

Hallazgo 2

Predominio de un medio



Fuente: archivo aportado por el grupo. Cobertura temporal pendiente de verificación.

5. Armas o medios registrados

ARMA DE FUEGO reúne **24,397** unidades, un **76.85%** de la cantidad registrada. La comparación incluye las 5 categorías de medio presentes en el archivo.

La figura V4 agrega por arma los resultados de Q4, que originalmente cruza arma y sexo. La suma se conserva al eliminar el desglose por sexo. La modalidad presunta y la caracterización permanecen disponibles en la dimensión contexto para análisis posteriores.


Interpretación y uso

El predominio observado orienta las preguntas descriptivas del equipo hacia el medio más frecuente. No prueba causas ni evalúa medidas de intervención; la fuente no contiene variables suficientes para ese tipo de conclusión.

Fuente: consulta Q4 sobre PostgreSQL; suma de CANTIDAD. Las etiquetas se normalizan en espacios y mayúsculas, sin reagrupar categorías arbitrariamente.

Hallazgo 3

Variación y cobertura



La serie contiene **72 meses**. El máximo observado es **561** unidades en **2022-01**; el mínimo es **353** en **2020-10**. Q1 calcula cambios con LAG, pero la anomalía de fechas impide interpretarlos como evolución completa de la criminalidad.

6. Limitaciones y próximos pasos

Origen y fechas. Obtener URL oficial, diccionario, criterios de selección y CSV crudo del catálogo. Verificar por qué faltan los días 13 a 31 antes de corregir fechas o sostener comparaciones temporales.

Identidad y cantidades. Solicitar un identificador de evento y la definición oficial de CANTIDAD. Revisar las filas idénticas con el proveedor; no eliminarlas por una coincidencia de atributos.

Comparabilidad. Integrar población del mismo periodo para tasas si la cobertura se valida. Para una carga incremental, usar claves de negocio estables y persistir las claves dimensionales.

Entrega y exposición. Confirmar aceptación del dataset, firmas y fecha con el docente: el PDF dice 23/24-sep-2026 y los avances 30-sep. Ensayar el guion de ocho minutos incluido.

Referencias: Proyecto 1.pdf (rúbrica y fases, pp. 1-3); 01-04_avance_proyecto.md; Excel aportado, Hoja1. No se ha atribuido el archivo a un editor oficial sin evidencia. Huella y conversión reproducible en datos/manifiesto.json.